

Tensorflow / keras

Anton Rusňák, František Gič

Parkinson

Projekt je zameraný na binárnu klasifikáciu dát ohľadom Parkinsonovej choroby. Binárnou klasifikujeme určujeme jedincov na základe atribútov frekvencie ich hlasu do tried zdravý/chorý.

Popis dát

Použitý dataset: <https://archive.ics.uci.edu/ml/datasets/parkinsons>

V dátach sa nachádza 195 záznamov. Dáta nebolo nutné predspracovávať, nakoľko už boli v stave s ktorým sa dalo priamo pracovať. Nebolo teda potrebné robiť One-hot encoding.

Trénovacie a testovacia dáta sme rozdelili v pomere 70 ku 30.

Sieť

Pri práci s modelom sme využívali aj väčší počet vrstiev, aj vyšší počet neurónov, avšak pri porovnaní výsledkov sme sa rozhodli použiť nasledovnú konfiguráciu:

- vstupnú vrstvu s 22 neurónmi (22 je počet vstupných atribútov).

- 3 skryté vrstvy s aktivačnou funkciou `RELU`.
- výstupnú vrstvu s 1 neurónom (binárna klasifikácia) a aktivačnou funkciou `Sigmoid`.

Na výpočet loss-u využívame funkciu `BinaryCrossEntropy`. Na vyhodnotenie presnosti modelu používame accuracy.

Optimizer Adam

Počas vypracovávania projektu sme vytvorili množstvo modelov, pre účely reportu sme vybrali 5 konkrétnych.

V grafoch sme zobrazili ich loss a accuracy pre trénovacie a testovacie dáta.

Pre všetky modely sme mali nastavený rovnaký počet epôch - 100. Z testovania sme vyvodili záver, že väčší počet epôch viedol k preučeniu modelu.

Adam - 1

Veľkosť batchu je 16, learning rate sme nechali defaultný - 0.001 Presnosť na trénovacích dátach mal model vysokú, ale čo sa týka krivky pri testovacích dátach, tá nemala konzistentné stúpania a mala často veľké výkyvy a nižšiu presnosť ako na trénovacích dátach.

Adam - 2

Veľkosť batchu je 64, learning rate 0.001 Vidíme, že model začal s oveľa nižšou presnosťou než ostatné modely s Adamom. Krivka je podobná modelu Adam - 1. Výsledná presnosť na trénovacích dátach je nižšia ako na Adam - 1, ale na testovacích dáta je vidieť nárast presnosti.


Adam - 3 a 5

Tieto dve siete sú rovnako nastavené s batchom o veľkosti celej množiny - 195 a learning rate-om 0.001. Aj pri rovnako nastavených sieťach vidno, aké dôležité je inicializovanie váh. Môžeme to vidieť na presnosti, kde Adam - 5 má o pár desatín lepšiu presnosť ako Adam - 3.

Adam - 4

nastavený batch na celú množinu a learning rate na 0,005. Na tréningových dátach, môžeme vidieť, že model 5 a 4 sa na začiatku chovali približne rovnako. Ale pri epoche 33 sa presnosť modelu 4 zvýšil rázne. Na testovacích dáta, ale modeli 4 a 5 dosahovali rovnaké hodnoty





Optimizer - RMSProp

Pre tento optimizer sme opäť vybrali len subset behov. Počet epôch bol 100. Na grafoch možno vidieť krivky presnosti a lossu pre jednotlivé behy.

RMSProp - 1 a 3

Batch size je nastavený na veľkosť 195, learning rate na 0,0001. Je zaujímavé ako sa hodnota úspešnosti držala na rovnakej úrovni až do 86 epochy. Ostatné hodnoty boli nastavené defaultne. Akonáhle sme momentum nastavili na 0.5 pri RMSProp - 3, tak úspešnosť po celú dobu tréningovania zostala rovnaká ako pri tréningových tak aj testovacích dátach.

Usudzujeme z toho nasledovné, a to, že sme sa s optimizérom dostali do lokálneho minima.

RMSProp - 2

Pri tomto modeli sme nastavili momentum na 0.5. Rozdiel oproti predhádzajúcemu modelu RMSProp 1 je taký, že sme mu skúsili zvýšiť learning rate, a to na hodnotu 0.001. Ostatné parametre boli defaultné. Pri sledovaní krivky si môžeme všimnúť výrazné skoky v accuracy. Krivka lossu zo začiatku v prvej desiatke epôch výrazne klesala, ale po zvyšok behu sa dostala na približne rovnaké hodnoty.

Zo skákajúcich hodnôt accuracy na oboch sadách usudzujeme, že na to mala výrazný vplyv vysoká hodnota learning rate-u.

RMSProp - 4


Tento model mal rovnaké nastavenia ako model 3. Jediný rozdiel, ktorý mohol tieto modely tak odlíšiť, sú inicializované váhy a optimizer našiel lepšie lokálne minimum.



Záver

V porovnaní mali oba z optimizerov - RMSProp aj Adam pomerne rovnaké hodnoty accuracy. Ako sme si mohli všimnúť, RMSProp bol však viac náchylnejší k stagnácií v lokálnom minime.

Z používateľského hľadiska je optimizer Adam pripravenejší na používanie out-of-the-box, kdežto

Created with  on Weights & Biases.

https://wandb.ai/nn2021/parkinson_tensor/reports/Tensorflow-keras--Vmlldzo1Njl4MDc